Przetwarzanie danych w chmurach obliczeniowych

MovieGraph

System wizualizacji zależności między filmami oparty o grafową bazę danych Neo4j

Autor:
Krzysztof Jabłoński

14 grudnia 2025

1 Wstęp

Celem niniejszego projektu było zaprojektowanie i wdrożenie aplikacji internetowej **MovieGraph**, służącej do wizualizacji i analizy powiązań między filmami. Głównym założeniem systemu wykorzystanie grafowej bazy danych, który w naturalny sposób odzwierciedla relacje zachodzące między filmami, aktorami itp..

1.1 Źródło danych

Dane zasilające system pochodzą z serwisu **The Movie Database (TMDB)**. Dane zostały poddane transformacji, aby dopasować je do struktury węzłów i krawędzi w bazie grafowej Neo4j. Dzięki temu aplikacja operuje na rzeczywistym zbiorze danych, obejmującym informacje o filmach, obsadzie, reżyserach, gatunkach oraz słowach kluczowych.

1.2 Dostępność rozwiązania

Aplikacja została wdrożona przy użyciu serwisu AWS EC2 i jest dostępna publicznie pod adresem:

`https://keyjay.pl/movieGraph`

2 Opis funkcjonalności aplikacji

Aplikacja MovieGraph umożliwia użytkownikom interaktywną eksplorację bazy danych filmowych. Interfejs został zaprojektowany w sposób minimalistyczny, skupiając się na wizualnej reprezentacji danych. Poniżej opisano kluczowe funkcje systemu.

2.1 Wyszukiwanie

Podstawowym punktem wejścia do aplikacji jest pasek wyszukiwania. System wspiera wyszukiwanie zarówno filmów, jak i osób (aktorów, reżyserów). Podczas wpisywania frazy, aplikacja dynamicznie komunikuje się z API, aby wyświetlić listę podpowiedzi (suggestions) dopasowanych do zapytania użytkownika. Pozwala to na szybkie odnalezienie interesującego obiektu bez konieczności wpisywania pełnej poprawnej nazwy.

2.2 Interaktywna wizualizacja grafu

Po wybraniu obiektu, aplikacja generuje dynamiczny graf powiązań. Główny obiekt (np. wybrany film) staje się węzłem centralnym, wokół którego rozmieszczane są węzły powiązane:

- **Obsada:** Aktorzy grający w filmie (połączeni krawędzią z nazwą roli).
- **Reżyserzy:** Osoby odpowiedzialne za reżyserię.
- **Gatunki:** Kategorie, do których film został przypisany.

Użytkownik może wchodzić w interakcję z grafem: przesuwać węzły, przybliżać i oddalać widok (zoom) oraz klikać w węzły sąsiednie, aby "rozwinąć"graf dalej i eksplorować kolejne powiązania (np. sprawdzić, w jakich innych filmach grał dany aktor).

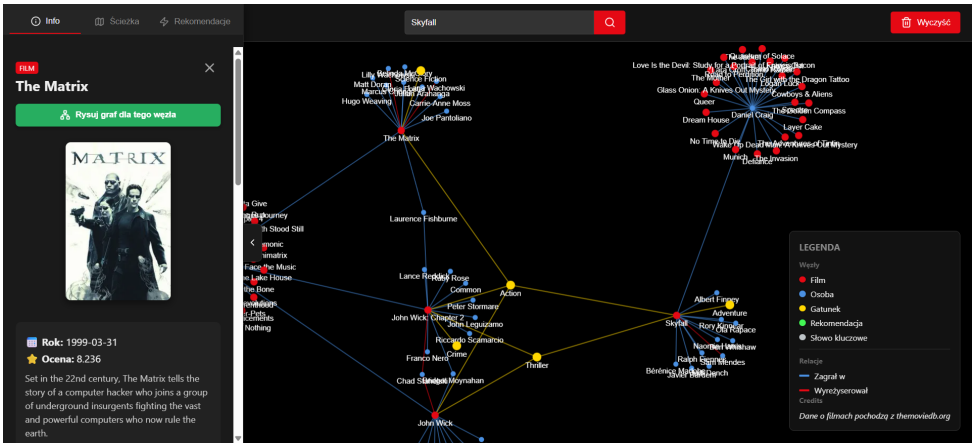

Rysunek 1: Mechanizm wyszukiwania i wizualizowani zależności między filmami.

2.3 Baza wiedzy na temat filmów

Aplikacja posiada funkcjonalność wyświetlania dodatkowych informacji na temat filmów oraz aktorów. Po kliknięciu w węzeł aktora lub filmu, wyświetlane są dodatkowe informacje na temat tego węzła.

2.4 Analiza ścieżek (Shortest Path)

Funkcjonalność pozwala na znalezienie najkrótszej ścieżki połączeń między dwoma dowolnymi węzłami w bazie (aktorami lub filmami).

Algorytm wyszukuje minimalną liczbę "kroków", które łączą obie osoby, a następnie wizualizuje tę ścieżkę na grafie. Algorytm świadomie nie wykorzystuje węzłów kategorii, ani słów kluczowych, ponieważ węzły te są zbyt ogólne i posiadają wiele połączeń.

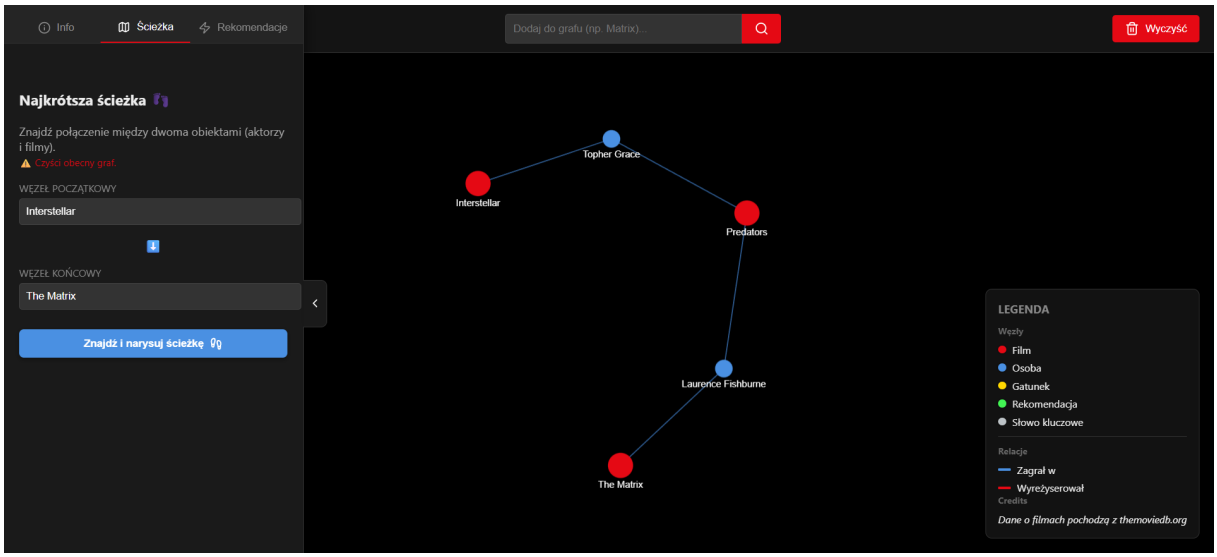

Rysunek 2: Wizualizacja najkrótszej ścieżki relacji między dwoma filmami.

2.5 Rekomendacje

System posiada również funkcjonalność rekomendacji filmów opartą na analizie struktury grafu. Na podstawie zbioru tytułów wskazanych przez użytkownika, algorytm identyfikuje filmy powiązane poprzez wspólnych sąsiadów, takich jak aktorzy, reżyserzy, słowa kluczowe czy gatunki.

Mechanizm rankingowy bazuje na prostym systemie punktacji ważonej. Oznacza to, że nie każde powiązanie ma taką samą wartość decyzyjną. Relacje o silniejszym znaczeniu są premiowane wyższą liczbą punktów. Przykładowo, wspólny reżyser generuje większy przyrost oceny dopasowania niż wspólne słowo kluczowe czy gatunek. Ostatecznie system sumuje wagi wszystkich krawędzi łączących kandydata z filmami bazowymi i zwraca trzy tytuły charakteryzujące się najwyższym wskaźnikiem dopasowania.

Ostatecznie powiązania między rekomendacjami, a listą filmów wybraną przez użytkownika są wizualizowane na grafie.

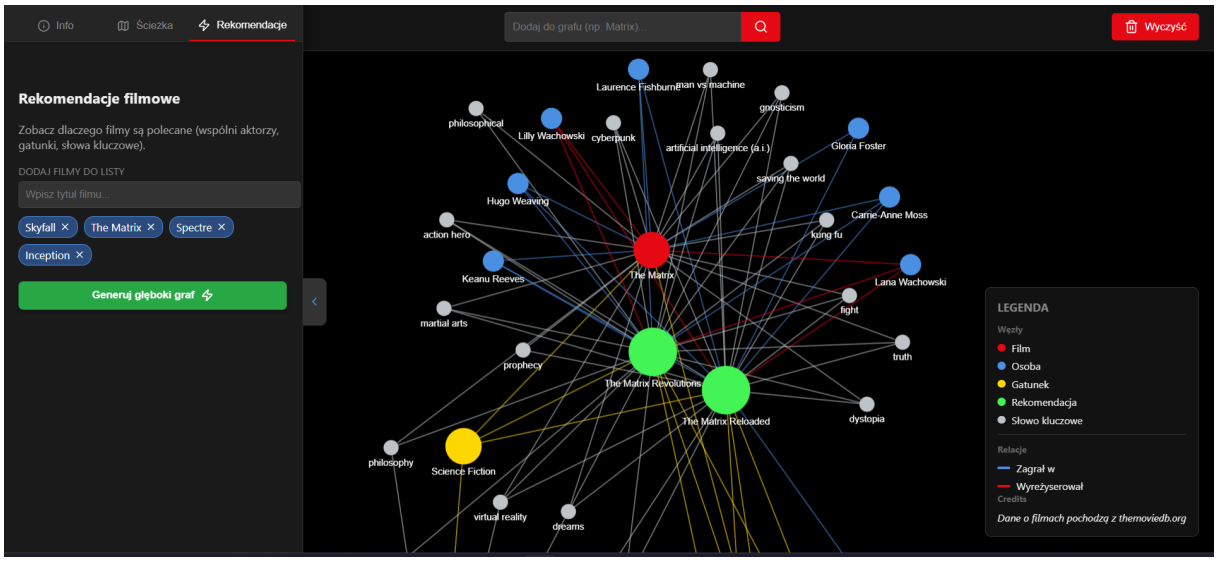

Rysunek 3: Wizualizacja rekomendacji filmów.

3 Struktura danych i Model Grafowy

Aplikacja w głównym stopniu opiera się na bazie danych Neo4j. W przeciwieństwie do relacyjnych baz danych, które przechowują dane w tabelach, Neo4j wykorzystuje model grafowy, składający się z węzłów (Nodes), relacji (Relationships) oraz właściwości (Properties).

Model ten w naturalny sposób odzwierciedla relacje między filmami.

3.1 Węzły (Nodes)

Węzły reprezentują główne encje w systemie. W bazie zdefiniowano cztery typy etykiet (Labels):

- `:Movie` – Reprezentuje pojedynczy film. Jest to centralny punkt większości zapytań.
  - `id`: Unikalny identyfikator z serwisu TMDB.
  - `title`: Tytuł filmu.
  - `released`: Data premiery.
  - `vote_average`: Średnia ocena filmu (0-10).
  - `overview`: Krótki opis fabuły.
  - `poster_path`: Ścieżka do plakatu filmowego.
  - `backdrop_path`: Ścieżka do grafiki tła.
- `:Person` – Reprezentuje osobę biorącą udział w produkcji (aktora lub reżysera).
  - `id`: Unikalny identyfikator osoby.
  - `name`: Imię i nazwisko.
  - `profile_path`: Ścieżka do zdjęcia profilowego.

- `:Genre` – Reprezentuje gatunek filmowy (np. "Action", "Drama").
  - `name`: Nazwa gatunku.
- `:Keyword` – Reprezentuje słowo kluczowe opisujące tematykę filmu (np. "space travel", "friendship").
  - `id`: Identyfikator słowa kluczowego.
  - `name`: Treść słowa kluczowego.

3.2 Relacje

Krawędzie w grafie są skierowane. Definiują one charakter połączenia między węzłami.

1. `(:Person)-[:ACTED_IN]->(:Movie)`
   - Określa, że dana osoba wystąpiła w filmie jako aktor.
   - **Właściwości relacji:**
     - `role`: Nazwa postaci odgrywanej przez aktora.
2. `(:Person)-[:DIRECTED]->(:Movie)`
   - Określa reżysera danego filmu. Relacja ta nie posiada dodatkowych atrybutów.
3. `(:Movie)-[:HAS_GENRE]->(:Genre)`
   - Przypisuje film do konkretnej kategorii gatunkowej. Jeden film może posiadać wiele relacji tego typu (np. być jednocześnie Komedią i Filmem Akcji).
4. `(:Movie)-[:HAS_KEYWORD]->(:Keyword)`
   - Łączy film z tagami tematycznymi.

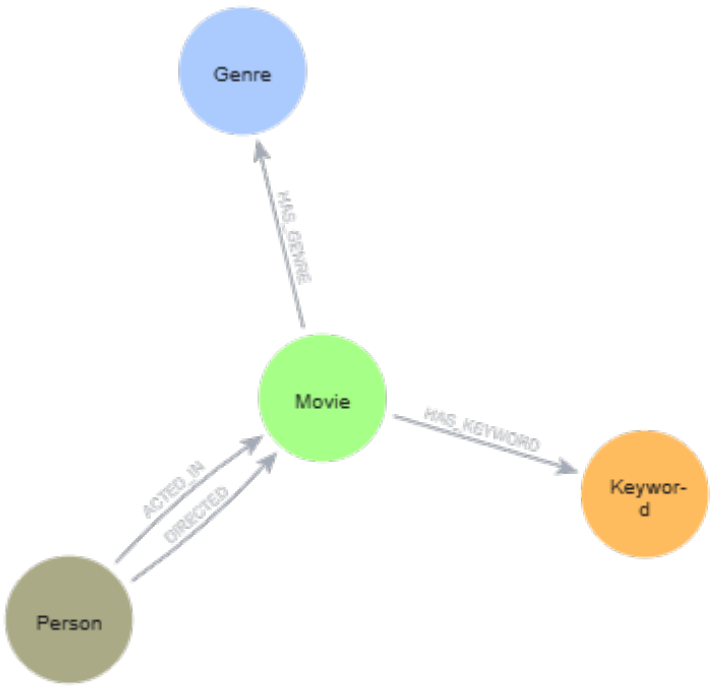

Rysunek 4: Wizualizacja schematu bazy danych.

3.3 Algorytmy grafowe

Neo4j oferuje natywne wsparcie dla algorytmów grafowych. Projekt MovieGraph aktywnie wykorzystuje funkcję `shortestPath`, aby znajdować najkrótsze połączenie między węzłami. W bazie grafowej jest to operacja standardowa, podczas gdy w SQL wymagałaby skomplikowanych zapytań rekurencyjnych.

4 Architektura Systemu i Przepływ Danych

System MovieGraph został zaprojektowany w klasycznej architekturze trójwarstwowej (Client-Server-Database), co zapewnia przejrzysty podział odpowiedzialności. Całość rozwiązania została wdrożona w środowisku chmurowym AWS.

4.1 Główne komponenty

System składa się z następujących elementów:

- **Warstwa Prezentacji (Frontend):** Aplikacja typu SPA (Single Page Application) stworzona w bibliotece **React.js**. Odpowiada za interfejs użytkownika oraz dynamiczną wizualizację grafu.
- **Warstwa Logiki (Backend):** Serwer aplikacji napisany w języku **Python** z wykorzystaniem frameworka **FastAPI**. Jego zadaniem jest obsługa zapytań API, walidacja danych oraz serwowanie plików statycznych frontendu.
- **Warstwa Danych:** Chmurowa baza grafowa **Neo4j (AuraDB)**, przechowująca strukturę filmów i ich powiązań.

4.2 Przepływ danych

Typowy proces obsługi żądania (np. generowanie rekomendacji) przebiega w czterech krokach:

1. **Żądanie klienta:** Aplikacja w przeglądarce wysyła asynchroniczne zapytanie HTTP (JSON) na adres serwera.
2. **Zapytanie do bazy:** Backend przetwarza żądanie na zapytanie w języku Cypher i wysyła je do bazy Neo4j.
3. **Odpowiedź:** Wynik z bazy (węzły i krawędzie) jest formatowany do postaci JSON i tą samą drogą zwracany do przeglądarki, gdzie następuje renderowanie grafu.